

Автоматическая разметка действий по видео

Не распознать кадр. Понять, что произошло во времени.

Temporal CV · мультимодальные модели · human-in-the-loop

[Открыть кейс ↗](#)

<https://talenttrack.aitalenthub.ru/hackathon/cases/466>

Игорь Якушев · ML-инженер · @igor_yakushev



Главная сложность: у действия нет готовых границ

Кадр можно классифицировать. Операцию нужно понять во времени.

01 Сегментация

Найти момент, где один шаг закончился, а следующий действительно начался.

02 Связь действие - объект

Не просто увидеть деталь, а понять, что именно с ней сделали в этом сегменте.

03 Ключевой кадр

Выбрать доказательство шага, а не случайный резкий или красивый кадр.

04 Неопределённость

Вернуть unknown и confidence, если модель не уверена, вместо уверенной выдумки.

Это задача на temporal reasoning, а не обычная классификация изображений.



граница → действие → объект → keyframe

Одна операция - три решения, которые можно проверить

Система должна объясняться через временную шкалу и контракт данных



00:00

00:11

ВЗЯТЬ

ПЕРЕМЕСТИТЬ

ПОЛОЖИТЬ

Сначала видим последовательность. Потом спорим о классе.


Контракт одного шага

```
{
  "start_ms": 2000,
  "end_ms": 5100,
  "action": "move",
  "object": "part",
  "keyframe_ms": 3800,
  "confidence": 0.87,
  "model_version": "pipeline-0.3"
}
```

Проверяем отдельно: границы, семантику, keyframe и уверенность.

Сильная команда не начинается с «идеальной модели»

За 6 дней выигрывает pipeline, который улучшается по одному узкому месту



baseline → измерение → точечное улучшение

01 Сначала baseline

FFmpeg + равномерные окна или change points + готовая VLM. Цель - получить первый полный прогон и метрику.

02 Потом качество

Temporal proposals, video embeddings, detector/SAM2, confidence и постобработка. Меняем только то, что реально просаживает score.

03 Затем продукт

Таймлайн, быстрые правки, воспроизводимый evaluation harness, JSON/CSV, latency и стоимость каждого прогона.


Новый dependency без измеримого прироста - не улучшение.

Архитектура: меняем модель, не ломая продукт

Один job, версионированный контракт и заменяемые этапы



Продуктовый контур




Логировать обязательно

schema_version · model_version · latency_ms · cost · error · artifacts

Не требуется: Kafka, Kubernetes и обучение большой модели с нуля.

Побеждает самый быстрый цикл проверки

Модель даёт черновик. Интерфейс превращает его в полезный результат.



01 Видео и сегменты рядом

Пользователь сразу видит, где модель ошиблась во времени.

02 Поля правятся независимо

Граница, действие, объект и keyframe не должны быть одной кнопкой «переделать всё».

03 Неуверенность ведёт к месту ошибки

Confidence и горячие клавиши сокращают именно ручную проверку.

Прогноз и правка хранятся отдельно: метрики остаются честными, данные - пригодными для улучшения модели.

Метрики связаны: плохая граница ломает всё дальше

Сначала совпал шаг, потом оцениваются семантика и продуктивный эффект

СЕГМЕНТАЦИЯ

$\geq 0,75$

Step-level F1

≤ 2 с

средняя ошибка границ

СЕМАНТИКА

$\geq 80\%$

действия и объекты

$\text{IoU} \geq 0,5$

для совпавшего шага

ПРОДУКТ

$\geq 3\times$

быстрее разметки с нуля

≤ 2 мин

обработка одного ролика

Правило честного сравнения

One-to-one matching: temporal IoU $\geq 0,5$ + правильный класс действия. Затем считаем precision, recall и F1.

100%

валидный JSON / CSV

Из разметки получается слой данных для робототехники

Вы строите не классификатор, а повторно используемый data product



видео → структурированные шаги → проверенный датасет

01 Обучение роботов

Демонстрации человека превращаются в корпус действий для следующих экспериментов.

02 Цифровые инструкции

SOP и учебные ролики становятся поисковой библиотекой шагов и объектов.

03 Контроль выполнения

Фактическую последовательность можно сравнивать с эталонной операцией.

Управление роботом - следующий этап, не MVP хакатона.

На финале нужен не красивый интерфейс. Нужен доказанный прогон.

- Новый ролик, которого не было в демо
- Автоматический черновик без ручной подготовки
- Одна реальная ошибка и её быстрая правка
- Валидный export + качество + latency + стоимость

Сильный финал = меньше ручного труда, а не больше магии.

Открыть кейс ↗

<https://talenttrack.aitalenthub.ru/hackathon/cases/466>

